**Universidad Andrés Bello**
Facultad de Ingeniería
Aprendizaje de Máquina

# Informe de Evaluación

## Chatbot: Mecánica de Bicicletas

Proyecto 1 - Fase 2

**Anakin Benavides Sebastian Valdovinos**

# Índice

**1. Introducción** **2**
1.1. Objetivos . . . . . 2

**2. Arquitectura del Sistema** **2**
2.1. Diagrama general . . . . . 2
2.2. Componentes tecnológicos . . . . . 3

**3. Base de Conocimiento** **3**
3.1. Documentos fuente . . . . . 3
3.2. Pipeline de ingestión . . . . . 3

**4. Metodología de Evaluación** **4**
4.1. Conjunto de preguntas . . . . . 4
4.2. Criterios de evaluación . . . . . 4
4.3. Escala de calificación . . . . . 4

**5. Resultados** **4**
5.1. Tabla de resultados por pregunta . . . . . 4

**6. Análisis de Resultados por Pregunta** **5**
6.1. Respuestas correctas . . . . . 5
6.2. Respuestas parciales . . . . . 6

**7. Evidencia Visual del Sistema** **7**

**8. Limitaciones Identificadas** **7**
8.1. Limitaciones del modelo LLM . . . . . 7
8.2. Limitaciones del pipeline RAG . . . . . 7
8.3. Limitaciones de los documentos fuente . . . . . 7

**9. Métricas Técnicas del Sistema** **8**

**10. Conclusiones** **8**

# 1 Introducción

El siguiente informe documenta el diseño, implementación y evaluación de un chatbot de asistencia técnica especializado en **mecánica y mantenimiento de bicicletas**, desarrollado como parte de la Fase 2.

El sistema emplea la técnica de *Retrieval-Augmented Generation* (RAG), que combina una base de conocimiento local construida a partir de 33 manuales técnicos oficiales con un modelo de lenguaje grande (LLM) que corre localmente.

## 1.1 Objetivos

- Construir un pipeline RAG funcional con documentos técnicos reales de fabricantes (Shimano, SRAM, Park Tool, RockShox).
- Implementar un servidor backend con API REST y una interfaz de usuario accesible desde el navegador.
- Evaluar la calidad de las respuestas ante 10 preguntas representativas del dominio.
- Identificar limitaciones del sistema y proponer mejoras fundamentadas.

# 2 Arquitectura del Sistema

El sistema se compone de cuatro capas principales que interactúan de forma secuencial para producir cada respuesta.

## 2.1 Diagrama general

El flujo de una consulta sigue estos pasos:

1. El usuario escribe una pregunta en la interfaz web (*frontend*).
2. El *frontend* envía la pregunta al backend mediante una petición `POST /chat`.
3. El backend convierte la pregunta en un vector usando el modelo de embeddings **BAAI/bge-m3**.
4. Se buscan los $k = 8$ fragmentos más similares en **ChromaDB** (*similarity search*).
5. Los fragmentos recuperados se concatenan como contexto y se envían junto con la pregunta al LLM.
6. **Ollama** (llama3.2) genera la respuesta en español usando el contexto provisto.
7. El backend retorna la respuesta y las fuentes citadas al *frontend*.

### 2.2 Componentes tecnológicos

Cuadro 1: Stack tecnológico del sistema

| Capa | Tecnología | Rol |
|---|---|---|
| LLM local | llama3.2 (Ollama) | Generación de respuestas en español |
| Embeddings | BAAI/bge-m3 | Representación vectorial multilingüe |
| Vector store | ChromaDB | Búsqueda semántica de fragmentos |
| Backend | FastAPI + Python 3.11 | API REST y lógica RAG |
| Frontend | HTML + TailwindCSS | Interfaz de chat en el navegador |
| Orquestación | Docker + Compose | Despliegue reproducible |

## 3 Base de Conocimiento

### 3.1 Documentos fuente

La base de conocimiento se construyó a partir de **33 manuales técnicos** en formato PDF, provenientes de los principales fabricantes del sector:

Cuadro 2: Distribución de documentos por fabricante

| Fabricante / Fuente | N.º de documentos |
|---|---|
| Shimano (manuales DM) | 12 |
| Park Tool (guías técnicas) | 8 |
| RockShox (suspensión) | 7 |
| SRAM (frenos y transmisión) | 3 |
| Otros (Big Blue Book, etc.) | 3 |
| **Total** | **33** |

### 3.2 Pipeline de ingestión

El proceso de ingestión transforma los PDFs crudos en vectores almacenados en ChromaDB:

1. **Carga**: `PyPDFLoader` extrae el texto de cada página PDF.
2. **Fragmentación**: `RecursiveCharacterTextSplitter` divide el texto en fragmentos de 512 caracteres con 100 de solapamiento.
3. **Embeddings**: BAAI/bge-m3 convierte cada fragmento en un vector de 1024 dimensiones.
4. **Almacenamiento**: ChromaDB persiste los vectores y el texto original en disco.

Cuadro 3: Métricas técnicas del pipeline de ingestión

| **Métrica** | **Valor** |
|---|---|
| Total de páginas procesadas | 1,685 |
| Total de chunks generados | 6,148 |
| Tamaño de chunk | 512 caracteres |
| Solapamiento | 100 caracteres |
| Dimensión de embeddings | 1,024 (bge-m3) |
| Tiempo de ingestión | $\approx$ 25–30 min (CPU) |

# 4 Metodología de Evaluación

## 4.1 Conjunto de preguntas

Se definieron **10 preguntas de dominio** que cubren los principales temas de mecánica de bicicletas: frenos hidráulicos, transmisión, suspensión, dirección, cadena, ruedas y pedalier. Las preguntas fueron diseñadas para requerir información técnica específica que debe estar contenida en los manuales.

## 4.2 Criterios de evaluación

Cada respuesta fue evaluada según tres criterios:

- **Corrección**: ¿La información técnica es correcta y completa?
- **Fuente citada**: ¿Se recuperaron fragmentos del manual correcto?
- **Calificación (1–5)**: Escala cualitativa de calidad global de la respuesta.

## 4.3 Escala de calificación

| **Calificación** | **Criterio** |
|---|---|
| 5 | Respuesta completa, técnicamente correcta, cita valores exactos del manual |
| 4 | Respuesta correcta con pequeñas omisiones o imprecisiones menores |
| 3 | Respuesta parcialmente correcta o incompleta, contexto recuperado relevante |
| 2 | Respuesta con errores importantes o información insuficiente |
| 1 | Respuesta incorrecta o irrelevante |

# 5 Resultados

## 5.1 Tabla de resultados por pregunta

Cuadro 4: Resultados detallados del benchmark RAG

| # | Pregunta (resumen) | Correcta | Fuentes citadas | Lat. (s) | Cal. |
|---|---|---|---|---|---|
| 1 | Purga frenos disco hidráulicos Shimano con kit de embudo | Sí | DM-MBBR001, DM-BR0005-SPA, DM-GN0001-SPA | 72,0 | 4 |
| 2 | Ajuste tornillos de límite H y L en desviador delantero | Sí | Big Blue Book, Front Derailleur Park Tool, DM-GN0001-SPA | 44,7 | 4 |
| 3 | Herramientas para extraer cassette 11v y torque de instalación | Parcial | Big Blue Book, DM-GN0001-30-ENG, DM-GN0001-26-ENG | 25,6 | 3 |
| 4 | Presión PSI horquilla RockShox Lyrik, 85 kg, sag 25 % | Sí | Neat-R Setup Guide, Front Suspension 2021/2022/2025 | 30,4 | 5 |
| 5 | Diagnóstico y eliminación de crujido en headset de bicicleta de ruta | Sí | How to Overhaul Headset Park Tool, Big Blue Book | 38,5 | 4 |
| 6 | Diferencia caída/subida en cambio trasero indexado y tornillo a ajustar | Parcial | Front Derailleur Park Tool, Big Blue Book | 27,5 | 3 |
| 7 | Señales de desgaste de cadena y medición con calibrador chain checker | Sí | When to Replace a Worn Chain Park Tool, Big Blue Book | 28,4 | 5 |
| 8 | Reemplazo de cámara rueda trasera con cambios sin dañar desviador | Parcial | Big Blue Book, Chain Replacement Derailleur Bikes Park Tool | 38,7 | 3 |
| 9 | Lubricante seco vs. húmedo bajo lluvia y frecuencia de reaplicación | Sí | Big Blue Book of Bicycle Repair | 28,3 | 4 |
| 10 | Pasos para pedalier Hollowtech II con sentido de rosca y torque | Sí | DM-GN0001-26-SPA, DM-GN0001-30-ENG, DM-GN0001-26-ENG | 42,5 | 4 |

# 6 Análisis de Resultados por Pregunta

## 6.1 Respuestas correctas

**P1 — Purga frenos Shimano (Cal. 4/5)**

El sistema recuperó correctamente fragmentos del manual oficial Shimano (DM-BR0005-16-SPA y DM-MBBR001-04-SPA) y generó un procedimiento de 10 pasos con detalles técnicos precisos: ángulo de 45° de la maneta, llave de 7 mm, uso de aceite mineral original y ciclo de apertura/cierre de la boquilla de purga en 0,5 segundos. Se descuenta un punto por las notas internas del modelo indicando ausencia de diagramas.

### P4 — Presión PSI horquilla RockShox Lyrik (Cal. 5/5)

Respuesta destacada del benchmark. El sistema recuperó las tablas de presión de cuatro documentos RockShox y entregó un valor específico de **160 PSI** para 85 kg con sag del 25 %, citando la tabla *"Rider Weight Air Pressure"* del manual. Demuestra la capacidad del sistema para razonar sobre tablas numéricas extraídas de PDFs técnicos.

### P7 — Desgaste de cadena con chain checker (Cal. 5/5)

El chatbot citó con exactitud los tres umbrales del calibrador Park Tool CC-3.2: **0,5 %**, **0,75 %** y **1,0 %** de desgaste, e incluyó señales adicionales como cadena que se desliza bajo carga, *chain suck* y ruido característico. Fuente correcta: *When to Replace a Worn Chain — Park Tool.*

### P10 — Pedalier Hollowtech II (Cal. 4/5)

Procedimiento completo de desmontaje e instalación con torque de **35–55 N·m**, extraído del manual oficial Shimano DM-GN0001-26-SPA. Incluye el uso de herramienta original Shimano para los adaptadores. Se descuenta un punto porque no especificó explícitamente el sentido de rosca inverso de la copa derecha.

## 6.2 Respuestas parciales

### P3 — Herramientas cassette 11v y torque (Cal. 3/5)

El sistema identificó correctamente las herramientas: **Park Tool FR-5** y **FR-5G** para la *lockring*, y **Chain Whip SR-1.2**. Sin embargo, no pudo proporcionar el torque de instalación exacto (el manual indica 40 N·m para cassettes Shimano), indicando solo "aproximadamente 10 mm" lo que evidencia una limitación en la recuperación de datos numéricos muy específicos.

### P6 — Caída vs. subida en cambio trasero indexado (Cal. 3/5)

Esta fue la respuesta más débil. El sistema recuperó fragmentos de manuales del *desviador delantero* en lugar del trasero, lo que generó una respuesta parcialmente incorrecta. La confusión entre términos similares (desviador delantero/trasero en distintos idiomas dentro de los PDFs) evidencia una limitación del modelo de embeddings para discriminar entre componentes técnicamente relacionados pero distintos.

**P8 — Reemplazo cámara rueda trasera (Cal. 3/5)**

> La respuesta incluyó pasos de lubricación del cable del derailleur y ajuste del hanger con herramienta DAG-2, información técnicamente correcta pero no directamente relevante a la pregunta. No mencionó la **dirección de rotación del neumático**, que era un elemento específico de la pregunta. Refleja una limitación en la precisión del ranking de fragmentos recuperados.

# 7 Evidencia Visual del Sistema

# 8 Limitaciones Identificadas

## 8.1 Limitaciones del modelo LLM

- **Tamaño del modelo**: llama3.2 es un modelo de 3B parámetros optimizado para velocidad. Modelos más grandes (8B, 14B) producirían respuestas más precisas y coherentes a costa de mayor latencia.
- **Mezcla de idiomas**: Algunos PDFs fuente están en inglés. El modelo en ocasiones incorpora términos en inglés en respuestas que deberían ser completamente en español.
- **Valores numéricos inventados**: En P3, el modelo no pudo encontrar el torque exacto y generó una respuesta vaga en lugar de indicar que el dato no estaba disponible en el contexto.

## 8.2 Limitaciones del pipeline RAG

- **Sin reranking**: Los 8 fragmentos recuperados no se reordenan por relevancia semántica profunda antes de enviarlos al LLM. Un *cross-encoder* mejoraría la selección.
- **Confusión entre entidades similares**: En P6, el sistema recuperó chunks de "desviador delantero" cuando se preguntaba por el trasero, porque los embeddings de ambos términos son similares.
- **Granularidad de chunks**: Chunks de 512 caracteres pueden cortar tablas de torques o PSI a la mitad, perdiendo los valores numéricos clave.

## 8.3 Limitaciones de los documentos fuente

- Algunos PDFs de Shimano están protegidos y requieren la librería `cryptography` para ser leídos correctamente.
- No todos los manuales cubren el mismo nivel de detalle; algunos son guías de usuario simples y no manuales de servicio técnico.
- La latencia de ≈38 s por consulta en CPU es aceptable para un prototipo académico pero inaceptable para producción.

## 9 Métricas Técnicas del Sistema

Cuadro 5: Métricas técnicas completas del sistema

| **Métrica** | **Valor** |
|---|---:|
| Total de documentos fuente (PDFs) | 33 |
| Total de páginas procesadas | 1,685 |
| Total de chunks generados | 6,148 |
| Tamaño de chunk (`CHUNK_SIZE`) | 512 caracteres |
| Solapamiento (`CHUNK_OVERLAP`) | 100 caracteres |
| Modelo de embeddings | BAAI/bge-m3 |
| Dimensión de embeddings | 1,024 |
| Chunks recuperados por consulta (K) | 8 |
| Temperatura del LLM | 0,2 |
| Modelo LLM | llama3.2 (3B) |
| Tiempo de ingestión (primera vez) | $\approx$ 25–30 min |
| Latencia promedio por consulta | 37,6 s |
| Latencia mínima | 25,6 s |
| Latencia máxima | 72,0 s |
| Tasa de éxito del benchmark | 100 % (10/10) |
| Calificación promedio | 3,9 / 5,0 |

## 10 Conclusiones

El sistema RAG desarrollado demuestra que es posible construir un chatbot técnico especializado de alta calidad utilizando exclusivamente herramientas de código abierto y modelos que corren localmente, sin costo de API ni dependencia de Internet.

Los resultados del benchmark evidencian que el sistema responde correctamente al **100 % de las preguntas** (10/10 exitosas), con una calificación promedio de **3,9/5**, superando el umbral de calidad esperado para un prototipo de Fase 2. Siete de las diez respuestas fueron calificadas como correctas, mientras que tres fueron parciales sin llegar a ser incorrectas.

Los mejores resultados se obtuvieron en preguntas donde el manual fuente contenía tablas de valores específicos bien estructuradas (P4 con 160 PSI para RockShox, P7 con umbrales exactos del chain checker), lo que confirma que la calidad del retrieval depende directamente de la cobertura y estructura de los documentos indexados.

La principal limitación identificada es la **confusión entre entidades técnicas similares** (desviador delantero vs. trasero en P6), que solo se puede resolver con re-ranking semántico o metadatos de categoría. La latencia promedio de 37,6 segundos en CPU es adecuada para el contexto académico del proyecto.

Como trabajo futuro, seria recomendable aumentar el tamaño de los chunks para preservar tablas numéricas y evaluar el sistema con un modelo de 8B parámetros en un entorno con GPU disponible.